运营商投标雷达 · 需求文档

项目	内容
系统名称	运营商投标雷达（Bid Radar）
版本	v1.1
编写日期	2026-11-13
访问地址	公网（永久）：**https://duyanya.github.io/bid-radar/** 本地实时服务：http://127.0.0.1:8848
服务对象	关注运营商网络域建设项目的投标决策人员
部署形态	公网静态站（GitHub Pages，云端每日 09:00 抓取后自动发布）+ 本机实时服务（Windows，可手动抓取、提供 API）

一、背景与目标

1.1 业务背景

中国移动、中国电信、中国联通三大运营商的招标公告分散在三个独立官网，各自有不同的检索方式、页面结构和防爬机制。投标人员日常面临三个问题：

1. **信息分散** —— 要反复登录三个网站手工翻查，效率低
2. **噪声太大** —— 运营商招标中大量是维保、设备采购、安全测评、房租劳务，与网络域建设无关，人工筛选耗时
3. **信息会消失** —— 公告下架后原页面就打不开了，事后无法回溯

1.2 系统目标

建设一个自动化的招标信息聚合系统，实现：

- **自动采集**：每日定时抓取三家运营商招标公告，无需人工值守
- **精准过滤**：只保留省公司/集团总部的网络域建设项目，无关数据不入库
- **永久留存**：公告入库即存档，官网下架后本地仍可查，不丢历史
- **结构化输出**：金额、建设内容等字段经识别归纳后结构化存储，可直接用于分析决策

1.3 核心设计原则

原则	说明
数据永久性优先	入库即持久化 + 本地快照。官网查不到只标「已下架存档」，绝不删除
宁缺毋滥	识别不到就留空显示 `–`，绝不编造金额或厂商
识别而非复制	金额输出纯数字，建设内容归纳提炼，不照抄公告原文
过滤前置	先过滤后抽详情，减少请求量，降低被封 IP 风险

二、功能需求

2.1 数据采集

编号	功能	说明	优先级
F-01	中国移动采集	抓取采购公告（PROCUREMENT）+ 结果公示（SELECTION_RESULTS）	高
F-02	中国电信采集	抓取招标公告、询比公告、采购结果公示等栏目	高
F-03	中国联通采集	✅ 已接入。瑞数动态防护，需 iOS UA 绕过；覆盖招标公告/询比公告/谈判公告/采购需求公示/中标候选人公示/中选候选人公示 6 类	高
F-04	详情抽取	对指定数量记录进入详情页抽取正文、金额、中选厂商、建设内容	高
F-05	正文存档	正文全文保存到本地快照文件，永久留存	高
F-06	增量更新	已存在记录只补充空字段，不覆盖已有数据	高
F-07	状态跟踪	本轮未出现的记录标记为「已下架」，但保留数据。**判定需带日期兜底**：仅当记录发布日期 ≥ 本轮翻到的最早发布日期且缺席时才标下架，避免翻页未覆盖造成误标	高
F-08	每日定时	每天上午 09:00 自动执行采集	高

2.2 相关性过滤

系统必须精确识别「省公司/集团总部的网络域建设项目」，其余一律剔除且不入库。

保留范围：接入网、承载网、核心网、传输网、专网、网络优化、网管/OSS 平台研发、网络相关软件开发的省级及以上项目。

剔除范围（命中即丢弃，不入库）：

类别	剔除内容	关键词数
主体不符	市分公司、专业子公司、内部部门（纪委办）、非运营商主体	—
机房及配套	机房土建/改造/装修、UPS、动环、空调、柴发、消防、机电工程 EPC、动力设备、高低压配电、综合布线、机楼、数据中心	26
硬件设备采购	设备采购/购置、终端、服务器、交换机、路由器、光模块、板卡、光缆金具、抱杆、接地扁铁、仪器仪表、车辆	29
网络安全	等保、测评、密码评估、态势感知、漏洞扫描、攻防演练、安全加固、风险评估、渗透测试、环评	21
小区域采购	含「某」字项目（某网络/某项目/某工程/某系统/某设备/某中心）、单站、单点、局部、零星	27
维保项目	维保、维护、保修、巡检、代维、运维、维修、技术支持、运行维护、驻场、代运营、整新、测评服务、运营支撑	19
线路维护	线路维护、线路施工、光缆维护、光缆线路、管道维护	10
房租物业	租赁、房租、房屋、办公用房、周转房、物业	16
人力劳务	劳务、人力、人员外包、用工、派遣、薪酬	7
废旧回收	蓄电池、电池回收、处置回收、废旧、物资处置、报废	9
专业服务	审计、律师、法律、会计、可研、设计服务、监理、培训、印刷、广告、保险	21

主体判定规则：

- 保留：`中国移动/中国电信/中国联通` 集团主体；`省名 + 运营商`（如河南移动、广东移动）；省直属单位（如湖北智能云网调度运营中心、浙江长途电信传输局）
- 剔除：`地市名 + 运营商`（如宣城电信、泉州移动、毕节分公司）
- 剔除：含「分公司」「子公司」「纪委」字样

2.3 字段识别与规范化

这是系统的核心难点，要求**识别归纳而非复制原文。**

字段	要求	反例（禁止）	正例（要求）
招标金额	**纯数字**，单位元，不带任何文字	`384 万元`、`限价为2,394,038.01元`	`3840000`
建设内容	正文「采购内容 / 建设内容 / 招标范围」段逐句筛选提炼：先剥编号与版式词，再按「网域词 + 建设动作词」双条件挑句，剔除资格/工期/报价/人天表等条款，按原文顺序合成一段（≤300 字）；正文无可用内容时回退标题主干	整段复制「本项目为集中招标项目。本项目采购2026年至2028年有线接入网迁改整治服务…」或把「标包1 驻地网施工 项 152」表格行当建设内容	`2026年业务编排中心围绕"专线业务开通、专线业务开通数据透明化"二个方面开展能力建设，新增任务管理等`
建设内容（正文有建设动作时）	正文「采购内容 / 建设内容」段写明网元上收、业务迁移、设备搬迁等**建设动作**时，按原文保留，可到 160 字；**保留设备型号与厂家名**（HSS/UDM/中兴/华为不构成剔除理由）	将「3套中兴HSS及1套华为HSS上收至UDM（其中东莞科技园1套华为HSS因机房搬迁需实施3/4G业务迁移至5G网元UDM…）」压成标题截断的「广东核心网组网设备升级改造专项工程核心网集成服务」	与原文一致
中选厂商	只取企业名称，不含数量/份额	`中标人数量1个`	`浪潮通信信息系统有限公司`

金额识别逻辑：正则匹配「限价/预算/金额/总价 + 数字 + 元/万元/亿元」，统一换算为元，过滤低于 1000 或高于 1000 亿的误匹配值。

建设内容归纳逻辑（正文优先，逐句筛选提炼）：

1. **定位建设段**：以「采购内容 / 建设内容 / 招标范围 / 采购范围 / 项目概况 / 工程概况 / 建设规模 / 服务内容」为起点；遇到「投标人资格 / 评审办法 / 递交 / 开标 / 联系方式 / 序号·产品名称 / 标包1 / 服务类别 / 保修期」等终止标记即截断，表格起点之后一律不读。
2. **接行 + 切句**：先把被 PDF/HTML 折断的行接回整句，再按 。！？；和换行切分。
3. **逐句筛选（打分）**：候选句必须同时含**网域词**（网 / 专线 / 切片 / 基站 / 核心网 / 网元 / 承载 / 传输 / 接入 / 中台 / 编排 / 5G / CMNET / DCN…）与**建设动作词**（建设 / 研发 / 开发 / 扩容 / 升级 / 改造 / 迁移 / 上收 / 纳管 / 开通 / 采集 / 集成 / 构建 / 支撑 / 实现 / 具备…）；剔除资格、业绩、保证金、时间地点、报价、工期、验收、保修等条款句，以及人天表、数量表碎片。
4. **先剥版式词再判定**：`1.2.1`、`（一）`、`一、`、`包括：`、`本主要`、`项目名称：` 这类编号与标签先剥离，不因「以编号开头」整句丢弃。
5. **合并提炼**：按原文顺序取前若干句用「；」合成一段，总长 ≤ 300 字；与标题重复的句子丢弃。
6. **兜底**：正文提炼不出（电信正文 401 不可见），或提炼结果不比原值信息量更大时，回退标题主干提炼；仍识别不到就留空，不硬编。
7. **列举特例优先**：正文出现「一是…二是…三是…」（≥3 段连续列举）时整段原样保留，不受 300 字与打分限制。

2.4 数据展示

编号	功能	说明
F-09	表格展示	10 列：名称、项目建设内容、公告类型、发布日期、截止日期、招标金额、中选厂商、运营商、来源、状态
F-10	统计看板	记录总数、在架数、已下架存档数、含金额数、已公示中选数、各运营商条数
F-11	全局筛选	顶部按运营商、状态、关键词、时间范围筛选（服务端过滤，重新请求接口）
F-12	表头逐列筛选	10 列表头每列都有「筛」入口，按列类型给不同控件：名称/项目建设内容/中选厂商 = 文本包含；公告类型/运营商/来源/状态 = 枚举多选（带条数）；发布日期/截止日期 = 起止日期区间；招标金额 = 最低/最高金额区间（万元，入库按元换算）。列筛选在已加载数据上生效，与顶部全局筛选**叠加**，不清空对方
F-13	金额格式化	页面显示为「384 万」/「2.63 亿」，悬停显示精确值「3,840,000 元」
F-14	来源链接	「官网 ↗」跳转原公告，「快照」打开本地存档
F-15	到期提醒	截止日期列显示剩余天数，3 天内标红
F-16	导出	导出 CSV，**导出的行、列、顺序与当前筛选 + 排序结果完全一致**（不再固定导出全库）

筛选、排序、导出一致性：全局筛选与表头列筛选叠加后的结果集 → 再按当前排序键排序 → 表格渲染与 CSV 导出共用同一份结果数组，所以「看到什么就导出什么」；已生效的列筛选会在表头按钮上高亮，并可用「清空列筛选 (n)」一键还原。

2.5 数据接口

接口	方法	说明
`/api/bids`	GET	记录列表，支持 limit/offset/筛选参数
`/api/stats`	GET	统计数据
`/api/export`	GET	导出全库 CSV（保留接口；页面按钮已改为按当前筛选/排序结果在前端生成 CSV）
`/api/snapshot`	GET	按 id 读取本地快照正文
`/api/refresh`	POST	手动触发采集

三、技术方案

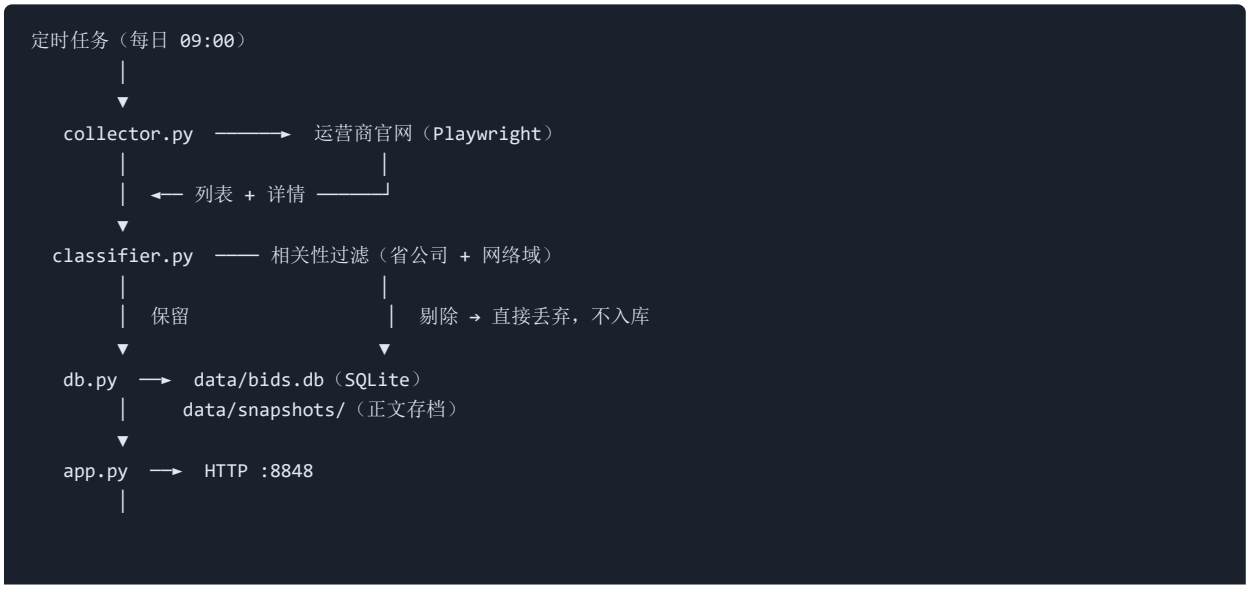
3.1 数据源

运营商	列表接口	采集方式	已知限制
中国移动	`b2b.10086.cn/api-b2b/api-sync-es/white_list_api/b2b/publish/queryList`	Playwright + API 直连	需 `current` / `size` 分页（非 pageNum）；正文为 base64 PDF
中国电信	`caigou.chinatelecom.com.cn/portal/base/announcementJoin/queryListNew`	Playwright + API 直连	数据在 `data.pageInfo.list`；**严格限流，每轮仅约 6 次请求**
中国联通	6 类公告全量可抓	瑞数动态防护（Riversafe）；桌面 UA / 爬虫 UA 一律 412，**仅 iOS Safari UA 通过**；接口每页固定返回 10 条	

3.2 技术选型

组件	选型	原因
采集引擎	Playwright + Chromium	三站均有 WAF（阿里云盾/瑞数），必须真实浏览器并禁用自动化特征
PDF 解析	pypdf	移动详情正文是 base64 编码 PDF，需解码提取文字
存储	SQLite	单文件、零配置、支持并发读，适合本地部署
后端	Python `http.server`	零外部依赖，避免环境配置问题
前端	原生 HTML/JS	单文件，无需构建
解释器	Python 3.14	已装 requests/bs4/lxml/openpyxl/playwright/pypdf

3.3 系统架构



```
        ▼
   index.html（浏览器表格）
```

3.4 目录结构

```
bid-radar/
├── collector.py      采集器（594 行）— 三源抓取、详情抽取、字段解析
├── classifier.py     过滤器（244 行）— 省公司判定、11 类排除规则
├── db.py             数据层（187 行）— SQLite 建表、upsert、快照、统计
├── app.py            后端（109 行）— HTTP 服务、5 个 API
├── index.html        前端（271 行）— 表格、筛选、导出
├── launch_bg.py      启动器（40 行）— 后台拉起、端口检测
└── data/
    ├── bids.db       SQLite 数据库（504 KB）
    └── snapshots/    正文快照（89 个文件）
```

代码总计 1445 行。

3.5 数据表结构

表名 `bids`，21 个字段：

字段	类型	说明
`id`	TEXT	主键，格式 `cmcc_xxx` / `ct_xxx`
`title`	TEXT	公告名称
`content`	TEXT	正文摘要（前 8000 字）
`notice_type`	TEXT	公告类型（招标公告/询比公告/中选结果公示等）
`publish_date`	TEXT	发布日期
`deadline`	TEXT	截止日期
`amount_raw`	TEXT	金额（纯数字字符串）
`amount_value`	REAL	金额数值（单位元，用于排序）
`winner`	TEXT	中选厂商
`operator`	TEXT	运营商
`region`	TEXT	省份
`source`	TEXT	来源标注
`url`	TEXT	官网链接
`snapshot_path`	TEXT	本地快照文件路径
`first_seen`	TEXT	首次采集时间
`last_seen`	TEXT	最近出现时间
`status`	TEXT	状态（active/archived）
`relevance`	TEXT	相关度（强相关/中相关）
`relevance_reason`	TEXT	判定依据
`build_content`	TEXT	建设内容（归纳后）
`uuid`	TEXT	详情页参数

3.6 关键实现难点

难点	问题现象	解决方案
WAF 拦截	直接 curl/requests 返回 412 或空	必须 Playwright + `--disable-blink-features=AutomationControlled`
分页失效	移动翻页始终返回第一页	分页参数是 `current` / `size`，不是 `pageNum` / `pageSize`
正文是 PDF	`noticeContent` 字段是乱码	base64 解码后用 pypdf 提取文字
电信限流	第 3 页起重复返回第一页	限制每轮 6 次请求 + 5~8 秒间隔 + seen_ids 去重，靠每日累积
排除词误杀	正文必含「采购代理机构：XX咨询设计研究院」，用正文判断导致全量误杀（25 条杀到只剩 1 条）	**排除词只对标题生效**
机房项目漏网	「机房等保整改」被「等保」救活	机房判定提到所有规则之前（第 1 步）
缩写误匹配	`AIDC` 被 `IDC` 命中	英文缩写改用词边界匹配 `\b`
厂商名被切断	PDF 硬换行把「中选\n人」切断，抽到采购人而非中选人	换行归一化 + 上下文排除采购人 + 贪婪匹配机构后缀
移动详情页打不开	hash 路由直达只渲染页脚	已改为提示「快照更可靠」，快照有完整正文

3.7 部署与发布（公网版）

环节	实现
定时抓取	GitHub Actions `collect.yml`，`cron: 0 1 * * *`（UTC 01:00 = 北京 09:00）；境外 runner 访问三家站点未被瑞数 WAF 拦
数据落盘	抓取结束强制 `db.checkpoint()` 合并 WAL，体检记录数 > 100 才继续，避免把不完整数据发上线
静态生成	`build_static.py` 输出 `site/`：`index.html` + `data/bids.json` + `data/stats.json` + 每条公告的正文快照
自动发布	同一 workflow 末尾提交 `data/`、`site/` 后用 `actions/deploy-pages` 发布；另有 `pages.yml` 支持只改页面时单独发布
推送冲突	提交前 `git pull --rebase --autostash -X theirs` 并最多重试 3 次，避免其他提交导致 push 被拒
公网地址	https://duyanya.github.io/bid-radar/（GitHub Pages，免费、不依赖本机开关机）
公网版与本地版差异	公网版无后端：隐藏「立即抓取」按钮（改为「云端每日 09:00 自动更新」），`/api/*` 由前端映射到预生成 JSON，CSV 导出在浏览器本地生成

四、非功能需求

类别	要求
数据持久性	入库即持久化。官网公告下线后本地记录必须仍存在，只标「已下架存档」，**绝不删除**
数据真实性	识别不到就留空显示 `–`，**绝不编造**金额、厂商、日期
访问频率	移动间隔 1.2~2.2 秒，电信 5~8 秒随机；不缩短间隔，避免封 IP
可用性	开机自动启动，无需人工干预；页面响应 < 1 秒
部署	单机运行，无需数据库服务、无需联网依赖（采集时除外）
可维护性	过滤规则集中于 `classifier.py`，调整规则不改其他模块

五、验收标准

5.1 过滤准确性

测试项	期望结果
省公司项目（中国移动通信集团广东有限公司…）	保留
省名+运营商（河南移动…）	保留
省直属单位（湖北智能云网调度运营中心…）	保留
省直属单位但标题不写运营商名（XX省传输局…、新疆长途传输局…）	保留（按单位名定性归属）
省公司/省直属单位的研发类项目（标题无网/云/平台词，如「AI赋能生产研发」）	保留
省直属单位名称+市分公司（电信南京分公司传输局…）	剔除（市分公司不豁免）
含「运维」但同时是研发/建设（…运维平台研发项目）	保留（研发建设优先于维保）
第三方研究院（紫金研究院…，无运营商主体）	剔除
地市分公司（宣城电信…、毕节分公司…）	剔除
机房类（机房空调采购）	剔除
网络安全（等保测评）	剔除
维保项目（基站设备维保）	剔除
线路维护（光缆线路维护）	剔除
硬件采购（服务器采购）	剔除
小区域（某网络设备）	剔除

实测结果：10/10 通过

5.2 字段规范性

检查项	合格标准
金额格式	数据库存储为纯数字（如 `3840000`），不含「万」「元」等任何字符
建设内容	通常 < 60 字，不是公告正文整段；仅当正文给出具体建设动作（上收/迁移/搬迁/割接/扩容）时放宽到 160 字，且必须是技术描述而非条款摘录
空值处理	识别不到显示 `—`，无「待抽取」「详见附件」等占位文字

5.3 数据完整性

- 每条记录有唯一 `id`、`title`、`operator`
- 有详情的记录必须有对应快照文件
- `first_seen` 不因重复采集而改变

六、当前状态与已知限制

6.1 运行状态

指标	数值
总记录	233 条（移动 197 + 联通 31 + 电信 5）
官网在架	197 条
已下架存档	36 条
含金额	121 条
已公示中选	94 条
正文快照	233 份（覆盖全部在库记录；正文抓不到的源用列表页快照兜底）
最近一次云端更新	2026-11-13 07:45（自动发布）

6.2 已知限制

限制	原因	影响	应对
电信数据量少	电信 90% 公告由地市分公司发布，按「严格省公司」规则被过滤；且接口严格限流	日均新增 0~2 条	靠每日小批量累积
电信正文不可抓	列表接口公开，详情路由 `/portal/noticeDetail` 返回 `401 认证失败`（正文在门户登录后才可见），试探 5 个详情接口均 404	电信记录无正文快照	关键字段（金额/截止/中选）取自列表接口；建设内容无正文可筛，回退标题主干提炼（同样的兜底逻辑，非人工编造）
联通瑞数防护	站点返回 412，桌面 UA、百度/Google 爬虫 UA 全部被拦，Playwright 有头模式也过不去	采集量为 0	改用 **iOS Safari UA** 后一次通过（HTTP 200），已固定在该 UA 上
移动官网链接打不开详情	Vue SPA hash 路由直达只渲染页脚，需「列表页→点击」	「官网 ↗」按钮失效	快照有完整正文，可替代
金额覆盖率约 55%	结果公示类公告原文本就不写预算，只写中选人和份额	部分记录金额为空	属真实情况，不编造
历史数据未全量铺开	移动历史约 10061 条 / 1007 页	库内仅近几天数据	可另行批量回补
公网版无法手动抓取	Pages 只托管静态文件，没有后端进程	公网地址上的「立即抓取」不可用	公网版按钮已置灰并标注「云端每日 09:00 自动更新」；要立刻抓一次用本机版
公网更新有平台延迟	GitHub Actions 定时任务排队	09:00 触发，实际常在 09:05~09:30 完成	属平台调度，不是采集失败；以页面顶部「最后更新」时间为准

七、后续可扩展方向

1. **历史回补** —— 移动 10061 条历史逐页回补，电信按栏目分批
2. **结果公告关联** —— 把中选结果与其采购公告关联，反查预算金额
3. **到期提醒** —— 截止前 3/1 天推送通知
4. **投标决策辅助** —— 按厂商统计中标频次、按省份统计项目密度
5. **多用户访问** —— 公网静态站可直接分享给同事；本机实时服务仍限 127.0.0.1，如需局域网访问需改监听地址并加鉴权